情報リテラシー　第10回「データサイエンス・AI（3）：データ分析と仮説検証サイクル」

2026年度　稲積 泰宏　／　教科書 pp.128-131

今日の流れ

1. 仮説検定（全数調査・標本調査・帰無仮説）
2. 仮説検証サイクルと PDCA
3. 散布図と相関係数
4. 線形回帰と予測
5. 訓練データとテストデータ
6. 相関関係と因果関係・擬似相関

今日の目標

この授業が終わったらできること

- データ分析の進め方および仮説検証サイクルについて説明できる。

仮説検定の基礎

仮説検定 確率的な考え方に基づいて仮説が正しいかを統計的に判断する方法

全数調査 対象全員を調べる調査

標本調査 一部を取り出して調べる調査。標本から母集団の特徴を推定する

無作為抽出（ランダムサンプリング） 偏りのない標本を得るための抽出方法

帰無仮説 「差がない」「効果がない」など，否定したい仮説

有意水準 帰無仮説を棄却する基準となる確率（例：5%）。p 値が有意水準を下回ったとき帰無仮説を棄却する

仮説検証サイクルと PDCA

仮説検証サイクル（科学）

- ① 仮説：「○○なら△△になるはず」と予想
- ② 検証：データで確かめる
- ③ 分析：結果を詳しく調べる
- ④ 結論：仮説は正しい？ 修正が必要？
- → 新仮説へ（繰り返し改善）

PDCA（ビジネス）

- Plan（計画）
- Do（実行）
- Check（確認）
- Act（改善）
- 共通点：一度で完璧を目指さず，繰り返し改善する

今日の仮説と検証方法

ポイント

- 仮説：「打率が高い選手ほど，本塁打も多い」
- データ：野球選手 40 人分の成績データ（架空）。セ・リーグ 20 人，パ・リーグ 20 人
- 項目：選手名・リーグ・打率・本塁打・打点・安打・出塁率
- 検証方法 1：散布図で視覚的に確認
- 検証方法 2：相関係数で数値的に確認
- 検証方法 3：線形回帰で予測モデルを作成

散布図と相関係数

散布図 2 つのデータの関係を見るグラフ。横軸と縦軸にそれぞれのデータを取り，点をプロットする

相関係数 相関の強さを数値化（-1〜+1）。今日のデータでは約 0.7 前後 → 比較的高い正の相関

注意 相関 ≠ 因果。相関が高くても「打率が本塁打を増やしている」とは断定できない。体格・スイング・戦術など他の要因が関係する可能性がある

線形回帰と予測

ポイント

- 線形回帰：散布図に「最も当てはまる直線（回帰直線）」を引く方法
- 数式：$y = ax + b$（x：説明変数（打率），y：目的変数（本塁打），a：傾き，b：切片）
- 決定係数（R^2）：今回のデータでは約 0.5〜0.6 → モデルが説明できるのは約半分程度
- 予測例：打率.300 の選手 → 約 15〜20 本程度／打率.250 の選手 → 約 10〜15 本程度
- 外れ値：打率低いのに本塁打多い選手，打率高いのに本塁打少ない選手 → 例外の発見につながる

訓練データとテストデータ

なぜ分けるのか

- モデルが未知のデータでも予測できるか確認するため
- 訓練データだけで評価すると，暗記しているだけの可能性がある
- 汎化性能（未知データへの対応力）を確認することが重要

分け方

- 訓練データ（60%）：モデルの学習に使う。このデータでパラメータを決める
- テストデータ（40%）：モデルの評価に使う。未知のデータとして扱う
- 流れ：訓練データで学習 → テストデータで評価 → 汎化性能を確認

相関関係と因果関係・擬似相関

相関関係と因果関係

- 相関関係：一方が増加すると他方が増加または減少する関係
- 因果関係：一方が原因となり他方が結果となる関係
- 因果関係の 3 規準：①共変性（相関あり）②時間的順序③交絡因子の排除
- 相関があっても因果関係があるとは限らない

擬似相関（見かけの相関）

- 例：アイスの売上↑の月は水難事故↑ → 散布図で相関がある
- しかしアイスが水難事故を引き起こすわけではない
- 交絡因子（気温）が両方に作用しているため
- → これを擬似相関という

Colab 実習：野球データの分析

実際にコンピュータで操作してください。

手順

1. Teams の課題からリンクをクリック
2. 「baseball_data.csv」を自分のマイドライブにコピー
3. セル 1 を実行（Google ドライブへのアクセス許可）
4. セル 2〜6 を順番に実行
5. 実行順序：①データ読み込み→②散布図→③相関係数→④train/test 分割→⑤線形回帰→⑥予測と可視化

課題・次回予告

課題（次回までに提出）

Word ファイルにスクリーンショットとコメントをまとめて Teams に提出すること

次回

「データサイエンス・AI（4）：機械学習の基礎」（教科書 -）

質問があれば授業後または Teams で受け付けます。

まとめ・チェックリスト

自己チェック（できたら ✓ をつけよう）

- □ 仮説検定（全数/標本調査・帰無仮説・有意水準・p 値）の基礎を理解した
- □ 散布図と相関係数・線形回帰による予測の基本を学んだ
- □ 相関関係と因果関係の違い・擬似相関に注意する重要性を把握した

質問があれば授業後または Teams で受け付けます。