情報リテラシー　第10回「データサイエンス・AI（3）：データ分析と仮説検証サイクル」

2026年度　稲積 泰宏　／　教科書 pp.126-129

今日の流れ

1. 仮説検証サイクルと PDCA
2. 散布図と相関係数
3. 線形回帰と予測
4. 訓練データとテストデータ
5. 相関関係と因果関係・擬似相関

仮説検証サイクルと PDCA

仮説検証サイクル（科学）

- ① 仮説：「○○なら△△になるはず」と予想
- ② 検証：データで確かめる
- ③ 分析：結果を詳しく調べる
- ④ 結論：仮説は正しい？ 修正が必要？
- → 新仮説へ（繰り返し改善）

PDCA（ビジネス）

- Plan（計画）
- Do（実行）
- Check（確認）
- Act（改善）
- 共通点：一度で完璧を目指さず，繰り返し改善する

今日の仮説と検証方法

ポイント

- 仮説：「打率が高い選手ほど，本塁打も多い」
- データ：野球選手 40 人分の成績データ（架空）。セ・リーグ 20 人，パ・リーグ 20 人
- 項目：選手名・リーグ・打率・本塁打・打点・安打・出塁率
- 検証方法 1：散布図で視覚的に確認
- 検証方法 2：相関係数で数値的に確認
- 検証方法 3：線形回帰で予測モデルを作成

散布図と相関係数

散布図 2 つのデータの関係を見るグラフ。横軸と縦軸にそれぞれのデータを取り，点をプロットする

相関係数 相関の強さを数値化（-1〜+1）。今日のデータでは約 0.7 前後 → 比較的高い正の相関

注意 相関 ≠ 因果。相関が高くても「打率が本塁打を増やしている」とは断定できない。体格・スイング・戦術など他の要因が関係する可能性がある

線形回帰と予測

ポイント

- 線形回帰：散布図に「最も当てはまる直線（回帰直線）」を引く方法
- 数式：$y = ax + b$（x：説明変数（打率），y：目的変数（本塁打），a：傾き，b：切片）
- 決定係数（R^2）：今回のデータでは約 0.5〜0.6 → モデルが説明できるのは約半分程度
- 予測例：打率.300 の選手 → 約 15〜20 本程度／打率.250 の選手 → 約 10〜15 本程度
- 外れ値：打率低いのに本塁打多い選手，打率高いのに本塁打少ない選手 → 例外の発見につながる

訓練データとテストデータ

なぜ分けるのか

- モデルが未知のデータでも予測できるか確認するため
- 訓練データだけで評価すると，暗記しているだけの可能性がある
- 汎化性能（未知データへの対応力）を確認することが重要

分け方

- 訓練データ（60%）：モデルの学習に使う。このデータでパラメータを決める
- テストデータ（40%）：モデルの評価に使う。未知のデータとして扱う
- 流れ：訓練データで学習 → テストデータで評価 → 汎化性能を確認

相関関係と因果関係・擬似相関

相関関係と因果関係

- 相関関係：一方が増加すると他方が増加または減少する関係
- 因果関係：一方が原因となり他方が結果となる関係
- 因果関係の 3 規準：①共変性（相関あり）②時間的順序③交絡因子の排除
- 相関があっても因果関係があるとは限らない

擬似相関（見かけの相関）

- 例：アイスの売上↑の月は水難事故↑ → 散布図で相関がある
- しかしアイスが水難事故を引き起こすわけではない
- 交絡因子（気温）が両方に作用しているため
- → これを擬似相関という

Colab 実習：野球データの分析

実際にコンピュータで操作してください。

手順

1. Teams の課題からリンクをクリック
2. 「baseball_data.csv」を自分のマイドライブにコピー
3. セル 1 を実行（Google ドライブへのアクセス許可）
4. セル 2〜6 を順番に実行
5. 実行順序：①データ読み込み→②散布図→③相関係数→④train/test 分割→⑤線形回帰→⑥予測と可視化

課題・次回予告

課題（次回までに提出）

Word ファイルにスクリーンショットとコメントをまとめて Teams に提出すること

次回

「データサイエンス・AI（4）：機械学習の基礎」（教科書 -）

質問があれば授業後または Teams で受け付けます。